

Tarımda Akıllı Gübreleme ve Sulama için Derin Q-Ağı Tabanlı Yaklaşım

Metehan Sözenli

Bilgisayar Mühendisliği Bölümü, Yüksek Lisans

Bursa Teknik Üniversitesi, Bursa, Türkiye

25435004037@ogr.btu.edu.tr

Doç. Dr. Kubilay Demir

Danışman — Derin Pekiştirmeli Öğrenme Dersi

Abstract

Sulama ve gübreleme kararları sıralı bir karar verme problemi olarak modellenebilir. Bu çalışmada, bitki verimini artırmayı ve aşırı gübre kaynaklı toksisiteyi sınırlamayı hedefleyen bir Derin Q-Ağı (DQN) uygulaması sunulmaktadır. Ortam, gerçek bir ürün verim veri setinden alınan istatistikler ile çarpanlı stres tabanlı basit bir büyüme modelinin birleştirildiği hibrit bir Markov Karar Süreci olarak kurulmuştur. Durum; nem, besin, sağlık ve toksisite gibi sürekli değişkenleri içerir. Ajan sekiz ayrıklı aksiyon arasından seçim yapar; gübre dozları veri dağılımına yaklaşık hizalanmıştır. Deneylerde eğitilmiş politika, rastgele politikaya göre daha yüksek verim ve daha düşük gübre kullanımı üretmiştir. Sonuçlar, ideal günlük tarla zaman serisinin yokluğu ve problemin göreceli basitliği göz önünde bulundurularak yorumlanmalıdır.

Anahtar Kelimeler—Derin Pekiştirmeli Öğrenme, DQN, Hassas Tarım, Gübreleme Optimizasyonu, Hibrit Simülasyon, Verim Yönetimi

1. Giriş

Sulama ve kimyasal gübre yönetimi modern tarımın en kritik operasyonel kararlarından birini oluşturmaktadır. Aşırı gübreleme üretim maliyetini yükseltmekte, toprak yapısını bozmakta, yüzey ve yeraltı sularını kirletmektedir. Yetersiz uygulama ise verim kaybına yol açmaktadır [10]. Bu kararlar doğası gereği sıralıdır: her günlük müdahale stokastik hava koşulları altında toprak nemini, besin durumunu, bitki sağlığını ve sonraki günlerin büyüme potansiyelini etkilemektedir.

Pekiştirmeli öğrenme (RL) sıralı karar verme için biçimsel bir çerçeve sunmaktadır. Tabular Q-Öğrenme yöntemleri düşük boyutlu ayrıklı ortamlarda uygulanabilmiş olsa da sürekli sensör okumaları (nem, besin konsantrasyonu, sı-

caklık, pH vb.) devreye girdiğinde boyutlanabilirlik sorunu ortaya çıkmaktadır. Derin Q-Ağları (DQN) eylem-değer fonksiyonunu sinir ağı ile yaklaşıklaştırarak, deneyim tekrarı ve hedef ağı ile eğitimi stabilize ederek bu sınırlamayı aşmaya yöneliktir [1].

Bu çalışmada tabular formülasyon yerine tam bir DQN ajanı kullanılmakta ve ortam gerçek bir ürün verim veri seti üzerinde kalibre edilmektedir. Taban verim istatistikleri ve gübre miktar dağılımları gerçek veriden alınmıştır. Günlük geçişler ise FAO AquaCrop [2] ve Doorenbos ile Kassam'ın klasik verim-tepki faktöründen [5] esinlenen hafif fizik tabanlı bir büyüme modeli ile yönetilmektedir. Sistem toksisiteyi ve kaynak israfını cezalandırırken verimi artıran politikalar öğrenmektedir.

Çalışmada şu adımlar atılmıştır: (i) gerçek verim ve gübre istatistikleri ile kalibre edilmiş Gymnasium uyumlu hibrit bir tarım ortamı, (ii) deneyim tekrarı ve hedef ağı içeren tam bir PyTorch DQN uygulaması, (iii) ödül, verim, zamansal fark kaybı, keşif oranı ve aksiyon dağılımını kapsayan kapsamlı deneysel değerlendirme, (iv) öğrenilen politikanın görsel simülasyonu.

2. Literatür Taraması

2.1 Tarımda Pekiştirmeli Öğrenme

Tarımda pekiştirmeli öğrenme uygulamaları son on yılda belirgin bir artış göstermiştir. Erken çalışmalar tabular Q-Öğrenme ve SARSA ile sulama zamanlaması ve gübre önerisi problemlerini ele almıştır. Bu yöntemler düşük boyutlu ayrıklı ortamlarda işe yarasa da sürekli sensör değişkenleri eklendiğinde durum uzayı hızla büyümekte ve tabular yaklaşımlar pratik olmaktan çıkmaktadır. Derin RL yöntemleri bu sorunu aşmak için devreye girmiştir.

Mnih ve arkadaşlarının DQN algoritması [1] deneyim

tekrarı ve hedef ağ ile derin sinir ağlarını Q-öğrenmeye entegre ederek Atari oyunlarında insan düzeyinde performans göstermiştir. Bu mimari sürekli veya yüksek boyutlu durum uzaylarına sahip tarımsal kontrol problemlerine doğrudan uyarlanabilmektedir. Sonraki iyileştirmeler arasında Double DQN, Dueling DQN ve Prioritized Experience Replay yer almaktadır. Aktör-eleştirmen ailesinden A2C, PPO ve SAC algoritmaları ise sürekli aksiyon uzayları için tercih edilmektedir [7].

CropGym [6] PCSE süreç tabanlı bitki simülatörü ile RL ajanını birleştiren açık kaynak bir Gymnasium ortamıdır. Ajan günlük azot uygulaması kararları vermekte; ödül verim ile gübre maliyeti arasındaki dengeyi yansıtmaktadır. SWAT tabanlı RL çerçeveleri [12] ve DSSAT entegrasyonları da raporlanmıştır. Bu çalışmalar yüksek doğruluklu fiziksel simülatörlerin RL için uygun ancak hesaplama açısından pahalı olduğunu göstermektedir. Buna karşılık bu çalışmada binlerce bölümün hızlı çalıştırılabilmesi için basitleştirilmiş bir geçiş modeli kullanılırken temel parametreler gerçek veri dağılımlarına bağlanmaktadır.

Bü et ve arkadaşları [15] derin RL'nin sulama planlamasında klasik optimizasyon yöntemlerine göre daha esnek olduğunu göstermiştir. Gautron ve arkadaşları [14] tarım için standart RL ortamlarının eksikliğine dikkat çekerek Gym uyumlu arayüzlerin önemini vurgulamıştır. Bu çalışma da Gymnasium uyumlu bir ortam sunarak tekrarlanabilirliği desteklemektedir.

2.2 Verim-Stres İlişkileri ve Fiziksel Modeller

Su stresi ile görel verim arasındaki ilişki FAO verim-tepki faktörü K_y ile tanımlanmaktadır [5]:

$$\left(1 - \frac{Y_a}{Y_m}\right) = K_y \left(1 - \frac{ET_a}{ET_m}\right). \quad (1)$$

Burada Y_a ve Y_m sırasıyla gerçek ve maksimum verim, ET_a ve ET_m gerçek ve maksimum evapotranspirasyonu ifade etmektedir. $K_y > 1$ bitkinin su açığına duyarlı olduğunu, $K_y < 1$ ise daha toleranslı olduğunu göstermektedir. Bu formülasyon birçok tahıl ve sebze türü için deneysel olarak doğrulanmıştır.

AquaCrop bu fikri genelleştirerek stres katsayılarını kanopi genişlemesi, stoma iletkenliği, yaşlanma ve hasat indeksine ayrı ayrı uygulamaktadır [2–4]. Model su verimliliği tabanlı bir biyokütle üretimi formülasyonu kullanmakta ve birçok ürün için parametrelendirilmiştir. DSSAT ve APSIM gibi diğer süreç tabanlı modeller de benzer stres mekanizmalarını içermektedir [16]. Bu çalışmada kullanılan büyüme modeli AquaCrop'un çarpanlı stres yapısını sadeleştirilmiş haliyle benimsemektedir; böylece tarımsal yorumlanabilirlik

korunurken RL için hesaplama maliyeti düşük tutulmaktadır.

Azotlu gübrelerin aşırı kullanımı toksisite, tuzluluk artışı ve verim kaybına yol açtığı literatürde belgelenmiştir [8, 9]. Azot döngüsündeki kayıplar hem çevresel hem ekonomik maliyet yaratmaktadır. Bu nedenle ödül fonksiyonunda toksisite cezası açıkça yer almaktadır. Besin eksikliği ve fazlalığının her ikisinin de stresi artırdığı bilinmektedir; modelde besin stresi hem düşük hem yüksek seviyelerde cezalandırılmaktadır.

2.3 Hassas Tarım ve Veri Odaklı Yaklaşımlar

Hassas tarım mekânsal ve zamansal değişkenliği dikkate alarak girdi kullanımını optimize etmeyi amaçlamaktadır [11]. IoT toprak sensörleri, hava istasyonları, uydru ve drone görüntüleri ile makine öğrenmesi teknikleri bu alanda yaygınlaşmıştır. Denetimli öğrenme yöntemleri verim tahmini için sıkça kullanılsa da sıralı karar verme problemi için RL daha doğal bir çerçeve sunmaktadır çünkü gelecek ödüllerin iskonto edilmiş toplamını maksimize etmektedir [17].

Gerçek tarımsal veri setlerinin günlük RL ortamlarına aktarılması veri kıtlığı nedeniyle genellikle kalibrasyon yoluyla yapılmaktadır. Bu çalışmada da aynı strateji izlenmektedir: taban verim ve gübre istatistikleri gerçek veriden alınmakta, günlük dinamikler ise literatüre dayalı stres modeli ile üretilmektedir. Bu yaklaşım tamamen sentetik ortamlara kıyasla daha yüksek dış geçerlilik sağlamaktadır [6].

3. Problem Formülasyonu

Otuz günlük ürün döngüsü sonlu ufuklu bir Markov Karar Süreci (MDP) olarak modellenmiştir. MDP (S, A, P, R, γ) beşlisi ile tanımlanmaktadır; burada S durum uzayını, A aksiyon uzayını, P geçiş olasılıklarını, R ödül fonksiyonunu ve γ indirim faktörünü ifade etmektedir.

3.1 Durum Uzayı

Her gün t ajan şu sürekli vektörü gözlemlemektedir:

$$s_t = [\tilde{t}, m_t, n_t, pH_t, T_t, H_t, L_t, h_t, \tau_t] \in \mathbb{R}^9. \quad (2)$$

Burada $\tilde{t} = t/30$ normalize gün indeksini, m_t toprak nemini (%), n_t görel besin seviyesini, pH_t asitliği, T_t sıcaklığı, H_t bağıl nemi, L_t ışık şiddetini, h_t bitki sağlık skorunu (0–100) ve τ_t toksisite indeksini göstermektedir. Bu değişkenler tipik IoT toprak ve hava sensörlerinden elde edilebilecek ölçümlerle örtüşmektedir.

3.2 Aksiyon Uzayı

Sekiz ayrık aksiyon gerçekçi yönetim kararlarını kodlamaktadır (Tablo 1). Gübre dozları gerçek veri setinde gözlenen ampirik dağılımın içinde yer almaktadır (medyan yaklaşık 137 kg/ha). Bu sayede ajanın seçebileceği gübre miktarları gerçek tarımsal uygulamalarla uyumludur. Tek uygulama dozları 40, 70 ve 140 kg/ha olarak belirlenmiş; böylece iki ile dört uygulama ile sezonluk toplamın gerçekçi aralığa ulaşması mümkün kılınmıştır.

Table 1: Ayrık Aksiyon Kümesi (gerçek veri yüzdeliklerine hizalı)

İndeks	Ad	Su (mm)	Gübre (kg/ha)
0	Bekle	0	0
1	Hafif Sulama	14	0
2	Yoğun Sulama	28	0
3	Gübre 40 kg	0	40
4	Gübre 70 kg	0	70
5	Gübre 140 kg	0	140
6	Sulama + Gübre 50 kg	16	50
7	Sulama + Gübre 90 kg	18	90

3.3 Geçiş Dinamikleri ve Büyüme Modeli

Aksiyon uygulandıktan sonra toprak değişkenleri (nem, besin, toksisite) güncellenmekte; ardından su, besin ve toksisite stresleri hesaplanmaktadır. Günlük görelî büyüme literatürdeki çarpanlı stres yaklaşımına uygun olarak şu şekilde ifade edilmektedir [2, 5]:

$$g_t = g_0 \cdot (1 - k_w \sigma_w) \cdot (1 - k_n \sigma_n) \cdot (1 - k_\tau \sigma_\tau). \quad (3)$$

Burada g_0 potansiyel günlük büyümeyi, σ_w , σ_n ve σ_τ sırasıyla su, besin ve toksisite streslerini, k_w , k_n ve k_τ ise stres katsayılarını göstermektedir. Kümülatif büyüme G ve toksisite cezası nihai verimi belirlemektedir:

$$Y = Y_{\text{base}} \cdot G \cdot (1 - \min(\tau/25, 0.55)). \quad (4)$$

Taban verim Y_{base} gerçek veri setinin ampirik dağılımından örneklenmektedir; böylece model çıktıları gerçek verim aralığı ile tutarlı kalmaktadır.

3.4 Ödül Fonksiyonu

Şekillendirilmiş ödül sağlıklı büyümeyi teşvik etmekte, toksisiteyi ve kaynak harcamasını cezalandırmakta, dönem sonunda verim bonusu vermektedir. Ayrıca sezonluk toplam gübre kullanımının gerçek veri medyanına yakın olması ödüllendirilmektedir. İndirim faktörü $\gamma = 0.97$ olarak seçilmiştir. Ödül tasarımı hem kısa vadeli sağlık iy-

ileştirmelerini hem de uzun vadeli hasat hedefini dengeleyecek şekilde ayarlanmıştır.

4. DQN Mimarisi ve Eğitim

4.1 Ağ Mimarisi

Eylem-değer fonksiyonu $Q(s, a; \theta)$ çok katmanlı algılayıcı (MLP) ile yaklaşıklaştırılmaktadır. Giriş katmanı 9 boyutlu durumu almakta; 256, 128 ve 64 boyutlu üç gizli katman ReLU aktivasyonu ve Katman Normalizasyonu kullanmakta; çıkış katmanı her ayrık aksiyon için bir Q-değeri üretmektedir. Katman Normalizasyonu eğitim kararlılığını artırmak için eklenmiştir [13].

4.2 Eğitim Algoritması

Eğitim klasik DQN algoritmasını [1] takip etmektedir:

- Deneyim tekrarı tamponu kapasitesi 60 000 geçiştir.
- Mini-yığın boyutu 128'dir.
- Hedef ağ her 300 gradyan adımında sert güncellenmektedir.
- ϵ -açgözlü keşif 1.0'dan 0.05'e üstel azalmaktadır.
- Optimizasyon için Adam algoritması kullanılmakta, öğrenme oranı 1×10^{-4} olarak ayarlanmaktadır.
- Kayıp fonksiyonu Smooth L1 (Huber) olarak seçilmiştir.
- Gadyan normu 5.0 ile kırılmaktadır.

Bir bölüm 30 günlük adımdan oluşmaktadır. Toplam 650 bölüm (yaklaşık 19 500 ortam etkileşimi) eğitilmiştir. Tekrarlanabilirlik için rastgele tohumlar sabitlenmiştir.

4.3 Gerçek Veri Entegrasyonu

Bu çalışmanın temel özelliklerinden biri ortamın gerçek tarımsal veri ile kalibre edilmesidir. Her bölümün başında Hindistan ürün verim veri setinden bir örnek çekilmektedir. Bu örnek taban verimi Y_{base} sağlamakta ve gübre yoğunluğunun öncel dağılımını bilgilendirmektedir. Günlük geçişler stokastik kalmakta, ancak ortaya çıkan verim dağılımı ampirik veriyle tutarlı olacak şekilde kısıtlanmaktadır. Böylece ajan yalnızca sentetik varsayımlara değil, gerçek tarımsal verim ve gübre istatistikleri üzerinde kalibre edilmiş bir ortamda öğrenmektedir. Bu yaklaşım sim-to-real boşluğunu azaltmaya yönelik pratik bir adım oluşturmaktadır.

Veri setinde gübre miktarının medyanı yaklaşık 137 kg/ha, birinci çeyrek yaklaşık 74 kg/ha ve üçüncü çeyrek yaklaşık

259 kg/ha'dır. Aksiyon setindeki dozlar bu yüzdeliklere göre belirlenmiş; ödül fonksiyonunda sezonluk toplamın [70, 260] aralığında olması ayrıca ödüllendirilmiştir.

5. Deneysel Sonuçlar

5.1 Öğrenme Eğrileri

Şekil 1 başlıca eğitim tanımlarını bir arada göstermektedir.

Öne çıkan gözlemler şunlardır:

- Kümülatif ödül rastgele politikaya özgü negatif veya düşük değerlerden yaklaşık 300 bölüm sonra kararlı pozitif bölgeye yükselmektedir.
- Ortalama nihai verim yaklaşık 3500 kg/ha düzeyine ulaşmakta; sezonluk toplam gübre kullanımı gerçek veri medyanına (≈ 137 kg/ha) yakın seyretmektedir.
- Zamansal fark kaybı istikrarlı biçimde azalmakta; bu da eylem-değer fonksiyonunun başarılı yaklaşılaştırıldığını göstermektedir.
- Keşif oranı sorunsuz biçimde $\varepsilon = 0.05$ tabanına inmektedir.
- Geç eğitim aksiyon istatistikleri hafif sulama ve 40 kg gübre uygulamalarını öne çıkarmakta; yüksek tek seferlik dozlar neredeyse hiç seçilmemektedir.

5.2 Nicel Değerlendirme

Tablo 2 yüz değerlendirme bölümü üzerinde açgözlü politika ($\varepsilon = 0$) performansını özetlemektedir.

Table 2: Açgözlü Politika Değerlendirmesi (100 bölüm)

Politika	Ort. Verim (kg/ha)	Std.	Ort. Ödül
Rastgele	2700	450	-1200
Erken DQN (bölüm 50)	3200	380	+200
Son DQN	3520	820	+660

Eğitilmiş ajan rastgele tabana göre rastgele tabana göre daha yüksek verim göstermektedir. Öğrenilen politika sezon boyunca hafif sulama ile nemi korumakta ve birkaç kez 40 kg gübre uygulayarak toplam gübre miktarını gerçek veri medyanına yaklaştırmaktadır. Yüksek tek seferlik dozlar toksite nedeniyle tercih edilmemektedir.

5.3 Politika Davranışı

Öğrenilen politika incelendiğinde ajanın nemi korumak için ağırlıklı olarak hafif sulama seçtiği, besin düştüğünde 40 kg gübre uyguladığı ve yüksek tek seferlik dozları (70–140 kg)

neredeyse hiç kullanmadığı görülmektedir. Sezonluk toplam gübre kullanımı ortalama ≈ 141 kg/ha olup gerçek veri medyanına (137 kg/ha) çok yakındır. Bu davranış ödüldeki toksite cezası ile gerçekçi gübre aralığı bonusunun ortak sonucudur ve tarımsal iyi uygulamalarla uyumludur. Aksiyon dağılımı grafiği (Şekil 1e) bu bulguyu nicel olarak desteklemektedir.

5.4 Görsel Gösterim

Pygame tabanlı görselleştirme tarlayı, bitki sağlığını ve ajanın günlük kararlarını göstermektedir. Gübre uygulamaları ve sulama olayları hafif parçacık efektleriyle belirtilmekte; üst bilgi ekranı gün, tahmini verim ve seçilen aksiyonu raporlamaktadır. Ortaya çıkan animasyon sıralı karar sürecini uzman olmayan izleyiciler için sezgisel hale getirmekte ve politikanın pratik sonuçlarını görsel olarak doğrulamaktadır.

6. Tartışma

Hibrit yapı, taban verim ve gübre istatistiklerinin ampirik kalibrasyonu ile şeffaf stres tabanlı büyüme modelinin birleşimi olarak saf simülasyon ile veri kılıfı arasında pratik bir denge sunmaktadır. Stres katsayıları su ve besin stresi için literatür aralıklarından esinlendiği için [2, 5] dinamikler tarımsal olarak yorumlanabilir kalmaktadır. Aynı zamanda model derin RL'nin gerektirdiği yüksek bölüm sayısını destekleyecek kadar hafiftir.

Öğrenilen politikanın sade görünmesi (ağırlıklı olarak hafif sulama ve 40 kg gübre) rastgele veya dengesiz bir sonuç değildir. Verilen ufuk ve stres dinamiklerinde ajan gereksiz yüksek dozları elemiş ve sezonluk toplamı gerçek veri medyanına yaklaştırmıştır. Bu sadeleşme, RL ajanlarının sıkça sergilediği bir özelliktir.

Bununla birlikte çalışmanın sınırları açıkça belirtilmelidir. Öncelikle, istenen ideal veri seti mevcut değildir. İdeal durumda her gün için nem, besin, uygulanan gübre ve sulama miktarı ile hasat sonucunu birlikte içeren uzun bir zaman serisi kullanılmalıydı. Eldeki veri seti ise büyük ölçüde sezonluk özet düzeyinde verim ve gübre istatistikleri sağlamaktadır; günlük karar-sonuç çiftleri doğrudan gözlenemektedir. Bu nedenle gerçek veri, geçiş dinamiklerini satır satır öğretmek için değil, taban verim ve gübre dağılımını kalibre etmek için kullanılmıştır. Günlük geçişler stres tabanlı model ile üretilmeye devam etmektedir. Bu, tamamen veri-güdümlü bir öğrenme iddiasından farklı, hibrit bir yaklaşımdır.

İkinci olarak, problem modern derin pekiştirmeli öğrenme ölçütlerine göre görece olarak basittir. Kısa ufuk, küçük ayrık aksiyon kümesi ve şekillendirilmiş ödül, öğrenmeyi kolay-




Figure 1: 650 bölümden elde edilen DQN eğitim tanıları. (a) Bölüm kümülatif ödülü ve 30 bölüm hareketli ortalaması. (b) Nihai verim yörüngesi; kesikli çizgi gerçek veri medyanını göstermektedir. (c) Zamansal fark kaybı (logaritmik ölçek). (d) Keşif oranı ϵ . (e) Eğitimin son %30’unda aksiyon frekansları. (f) Eğitimin ikinci yarısında gerçekleşen verim histogramı.

laştırmaktadır. Çalışmanın katkısı zor bir kıyaslama görevini kırmak değil; tabular Q-Öğrenme’den DQN’e geçiş, gerçek istatistiklerle kalibrasyon ve rastgele politikaya karşı sistem- atik karşılaştırmadır.

Diğer sınırlılıklar arasında sabit 30 günlük ufuk, tarla içi mekânsal heterojenliğin olmaması, çevrimiçi hava tahminlerinin bulunmaması ve tam AquaCrop/DSSAT yerine sadeleştirilmiş büyüme modeli sayılmaktadır. Gelecek çalışmalar daha uzun mevsimsel ufuklar, sürekli aksiyon uzayları (PPO veya SAC), günlük ölçümlü tarla veri setleri ve süreç tabanlı simülasyonlarla daha sıkı bağlantı içerebilir [6].

7. Sonuç

Bu çalışmada akıllı günlük gübreleme ve sulama için DQN tabanlı bir çözüm sunulmuştur. Gerçek ürün verim istatistikleri ile hafif fizik tabanlı büyüme modelinin birleştirilmesi sayesinde ajan, toksisiteyi kontrol altında tutarken verimi rastgele politikaya göre artıran politikalar öğren-

miştir. Sezonluk gübre kullanımı gerçek veri medyanına yakın seyretmiş; eğitim tanıları ve görsel karşılaştırma politikanın katkısı desteklemiştir.

Sonuçlar, ideal günlük tarımsal zaman serisinin yokluğu ve problemin DRL açısından görece basitliği nedeniyle sınırlı bir kapsamda yorumlanmalıdır. Katkı, mükemmel bir tarla otonomisi iddiası değil; tabular yaklaşımdan DQN’e geçişin, hibrit kalibrasyonun ve tekrarlanabilir bir deney düzeneğinin ortaya konmasıdır.

References

- [1] V. Mnih vd., “Human-level control through deep reinforcement learning,” *Nature*, c. 518, no. 7540, ss. 529–533, 2015.
- [2] D. Raes, P. Steduto, T. C. Hsiao ve E. Fereres, “AquaCrop—The FAO crop model to simulate yield response to water: II. Main algorithms and software de-

- scription,” *Agronomy Journal*, c. 101, no. 3, ss. 438–447, 2009.
- [3] T. C. Hsiao vd., “AquaCrop—The FAO crop model to simulate yield response to water: III. Parameterization and testing for maize,” *Agronomy Journal*, c. 101, no. 3, ss. 448–459, 2009.
- [4] P. Steduto, T. C. Hsiao, D. Raes ve E. Fereres, “AquaCrop—The FAO crop model to simulate yield response to water: I. Concepts and underlying principles,” *Agronomy Journal*, c. 101, no. 3, ss. 426–437, 2009.
- [5] J. Doorenbos ve A. H. Kassam, “Yield response to water,” FAO Irrigation and Drainage Paper No. 33, Food and Agriculture Organization of the United Nations, Roma, 1979.
- [6] H. Overweg, H. N. C. Berghuijs ve I. N. Athanasiadis, “CropGym: A reinforcement learning environment for crop management,” arXiv:2104.04326, 2021.
- [7] Z. Wang vd., “Reinforcement learning-based agricultural fertilization and irrigation,” *Agriculture*, c. 15, no. 8, s. 252, 2025.
- [8] F. Salvagiotti vd., “Nitrogen uptake, fixation and response to fertilizer N in soybeans: A review,” *Field Crops Research*, c. 108, no. 1, ss. 1–13, 2008.
- [9] K. C. Cameron, H. J. Di ve J. L. Moir, “Nitrogen losses from the soil/plant system: A review,” *Annals of Applied Biology*, c. 162, no. 2, ss. 145–173, 2013.
- [10] D. Tilman vd., “Agricultural sustainability and intensive production practices,” *Nature*, c. 418, ss. 671–677, 2002.
- [11] N. Zhang, M. Wang ve N. Wang, “Precision agriculture—A worldwide overview,” *Computers and Electronics in Agriculture*, c. 36, no. 2–3, ss. 113–132, 2002.
- [12] M. Madondo vd., “A SWAT-based reinforcement learning framework for crop management,” AI for Social Good Workshop, 2023.
- [13] J. L. Ba, J. R. Kiros ve G. E. Hinton, “Layer normalization,” arXiv:1607.06450, 2016.
- [14] R. Gautron vd., “gym-DSSAT: A crop model turned into a Reinforcement Learning environment,” arXiv:2207.03270, 2022.
- [15] J. Buet vd., “Deep reinforcement learning for irrigation scheduling,” *Computers and Electronics in Agriculture*, 2022.
- [16] J. W. Jones vd., “The DSSAT cropping system model,” *European Journal of Agronomy*, c. 18, no. 3–4, ss. 235–265, 2003.
- [17] A. Kamilaris ve F. X. Prenafeta-Boldú, “Deep learning in agriculture: A survey,” *Computers and Electronics in Agriculture*, c. 147, ss. 70–90, 2018.